



西安交通大学
XI'AN JIAOTONG UNIVERSITY

计算机科学与技术学院

西安交通大学

基于层级语义建模与多智能体 协同推理的免训练视频摘要方法

**Training-free Video Summarization via Hierarchical Semantic Modeling
and Multi-agent Collaborative Reasoning**

姓名：刘明圻

2026 年 4 月

1 研究背景与动机

研究背景



- 视频数据爆炸式增长，信息过载问题日益突出
- 视频摘要：自动识别并保留最具代表性的帧或片段，支持用户快速理解视频主题
- 传统方法（监督/无监督/弱监督）依赖标注数据与任务特定训练，跨场景迁移能力有限

研究趋势

多模态大语言模型 (MLLMs) 的发展为免训练 (Training-free) 视频摘要提供了新范式——无需额外参数更新，利用语言推理能力完成语义分析与关键片段筛选

现有方法的不足与本文动机



现有方法局限

- ① 高层语义建模不足——难以刻画视频主题
- ② 单一评分器——无法兼顾多维评价目标
- ③ 时序上下文利用有限——长视频一致性差

本文两条技术路线

- ① 层级语义建模
帧 → 场景 → 视频的多级语义理解
- ② 多智能体协同推理
Planner + 多 Expert 多维度协同评分

论文结构



- ① 第一章：绪论——研究背景、研究现状与研究内容
- ② 第二章：相关理论基础与技术原理
- ③ 第三章：基于层级语义建模的免训练视频摘要方法
- ④ 第四章：基于多智能体协同推理的视频摘要方法
- ⑤ 第五章：结论与展望

2 相关理论基础

关键技术基础



大语言模型

- Transformer 自注意力架构
- 提示工程 (Prompt Engineering)
- 多模态语义对齐

智能体与协作

- 基于 LLM 的 Agent 决策
- 角色化提示实现职责分离
- 多智能体协同机制

3 层级语义建模的免训练视频摘要方法

方法总览（第三章）




图: 基于大语言模型的免训练视频摘要框架结构图


阶段一：视频场景划分



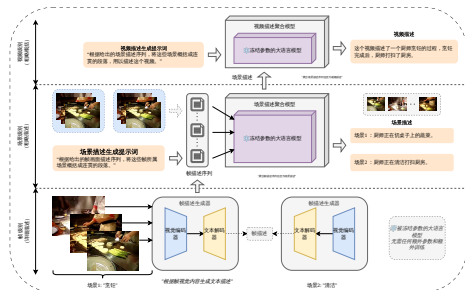
- 采用 KTS 算法对视频进行结构化分段
- 优化目标:

$$\min_B J(B) = \sum_{k=1}^K \text{Var}(s_k) + \lambda K$$

- 将连续视频流组织为语义相近的场景单元 $\{s_1, s_2, \dots, s_K\}$




阶段二：多级语义描述生成



图：多级视频语义描述生成流程

- 帧级描述: $Cap_f(t) = \text{VLM}(I_t; \theta_{\text{VLM}})$
- 场景级聚合:
 $Cap_s(k) = \text{LLM}_{\text{scene}}(\mathcal{T}_k; \theta_{\text{LLM}})$
- 视频级摘要: $Cap_v = \text{LLM}_{\text{video}}(\{Cap_s(1), \dots, Cap_s(K)\}; \theta_{\text{LLM}})$

阶段三：全局主题约束的场景语义评分



- 联合输入场景描述 $Cap_s(k)$ 与视频级摘要 Cap_v

- LLM 评估该场景对整体主题的贡献

$$S_{LLM}(k) = \text{Norm}(\text{LLM}(\Pi(Cap_v, Cap_s(k))))$$

4

多智能体协同推理的视频摘要方法

方法总览（第四章）





图: 基于大语言模型智能体协同的视频摘要方法总览

阶段二：全局规划与多专家协同评分



图：全局规划与多专家协同评分流程

第四章实验结果——秩相关性对比

方法	SumMe		TVSum	
	ρ	τ	ρ	τ
dppLSTM (2016)	0.049	0.040	0.055	0.042
VASNet (2018)	0.170	0.160	0.170	0.160
DSNet-AB (2020)	0.059	0.051	0.129	0.108
DSNet-AF (2020)	0.046	0.037	0.138	0.113
DMASum (2020)	0.089	0.063	0.267	0.203
PGL-SUM (2021)	—	—	0.157	0.206
MSVA (2021)	0.230	0.200	0.210	0.190
iPTNet (2022)	0.119	0.101	0.163	0.134
CSTA (2024)	0.274	0.246	0.255	0.194
LLMVS (2025)	0.282	0.253	0.275	0.211
第三章方法	0.267	0.218	0.280	0.191
本章方法	0.282	0.214	0.323	0.224



- TVSum $\rho=0.323$ 取得最高 Spearman 系数
- 完全免训练条件下取得与 LLMVS 可比甚至更优的排序表现

表：第四章方法与代表性方法的秩相关性对比

5 结论与展望

未来工作方向



西安交通大学
XI'AN JIAOTONG UNIVERSITY

- 1 探索更自适应的视频分段策略，提升分段与事件边界一致性
- 2 研究更稳定的记忆组织与检索机制，增强长视频全局一致性
- 3 优化帧级映射机制，使段级推理结果更精确地对齐到帧级分数
- 4 引入更强的多模态描述模型与更细分的专家角色
- 5 提升系统运行效率与多模型协同扩展能力



西安交通大学
XI'AN JIAOTONG UNIVERSITY

谢谢

基于层级语义建模与多智能体
协同推理的免训练视频摘要方法

刘明圻

2026 年 4 月