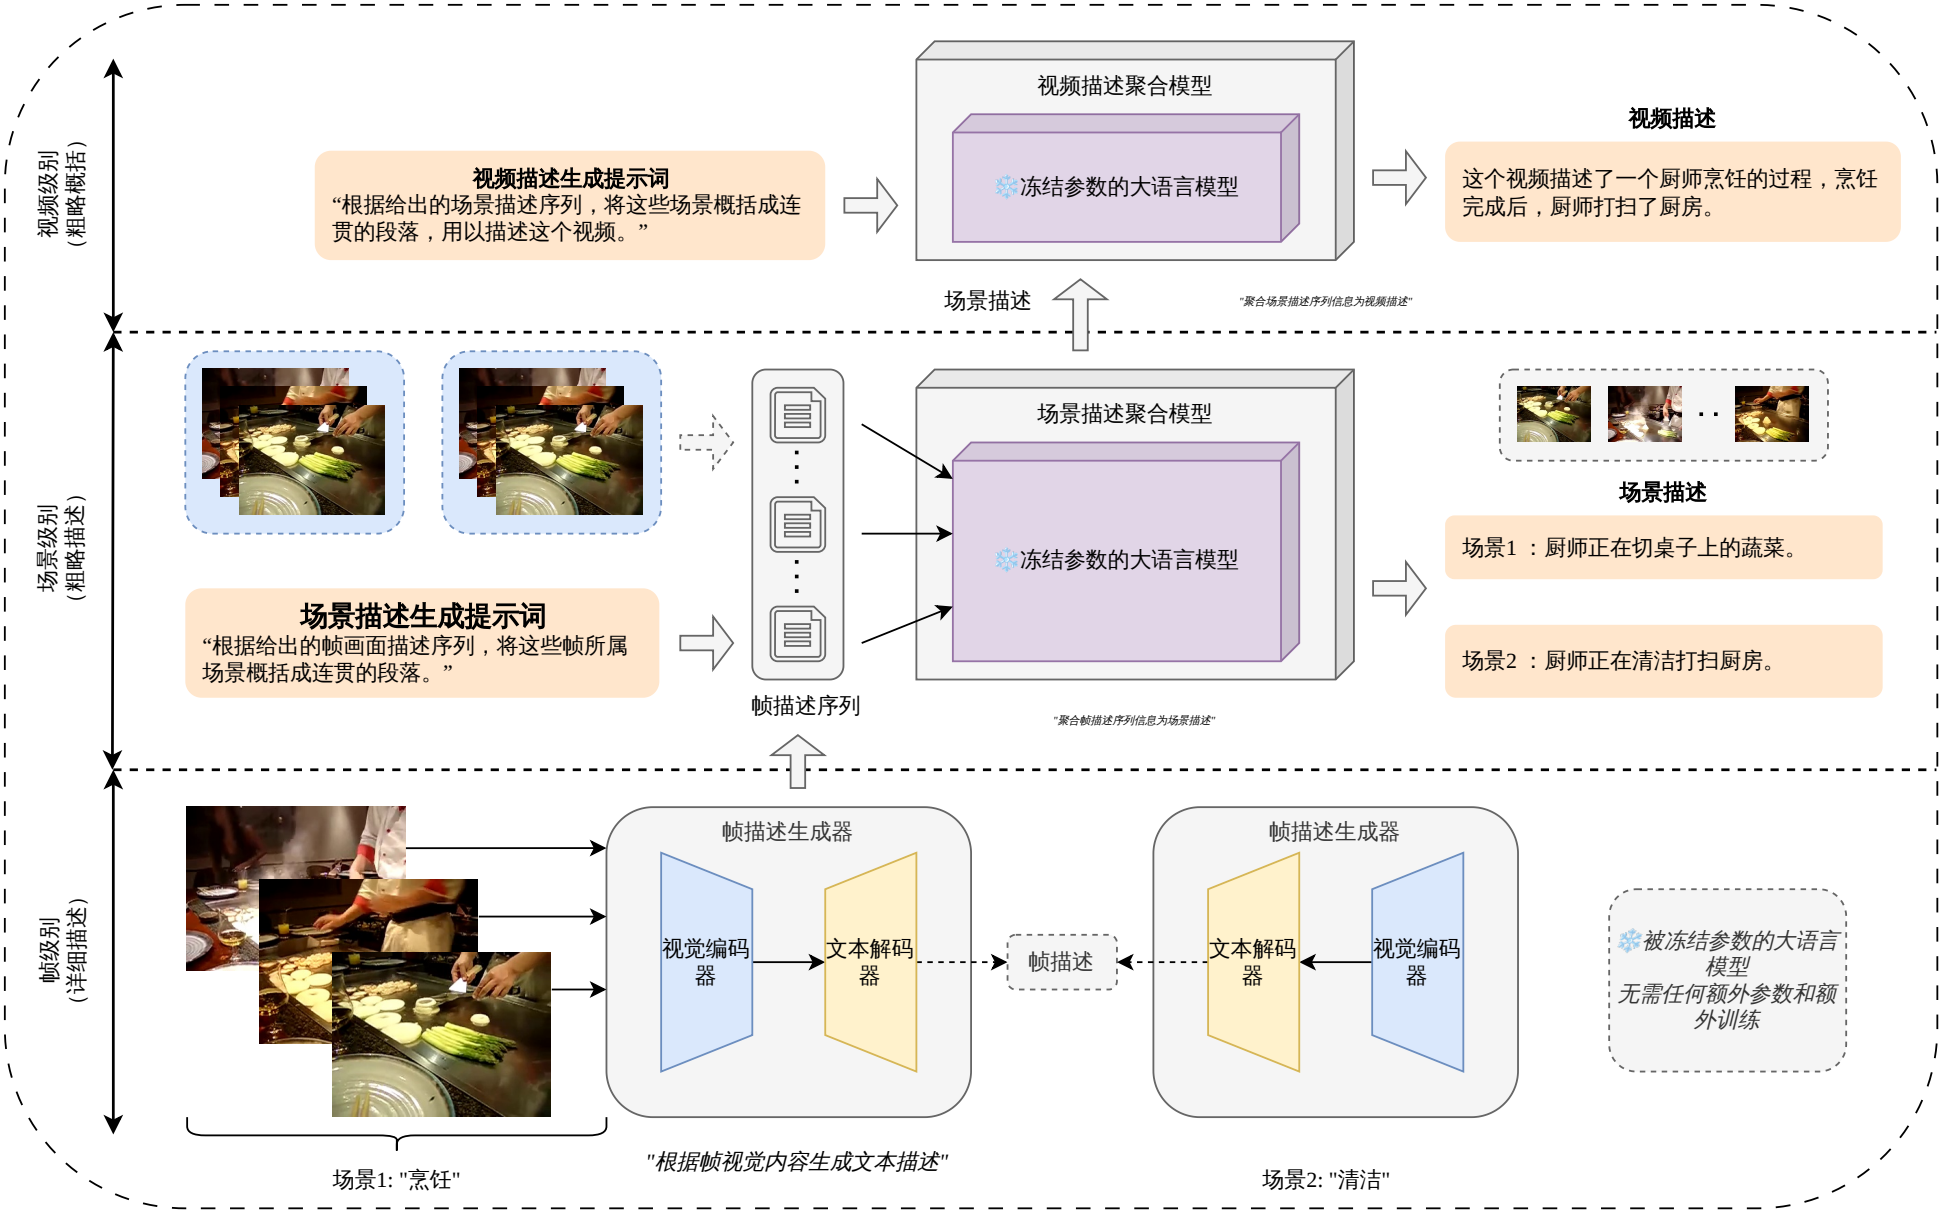
视频级别
(粗略概括)
视频描述生成提示词
“根据给出的场景描述序列，将这些场景概括成连贯的段落，用以描述这个视频。”
视频描述聚合模型
冻结参数的大语言模型
视频描述
这个视频描述了一个厨师烹饪的过程，烹饪完成后，厨师打扫了厨房。
场景描述
"聚合场景描述序列信息为视频描述"
场景级别
(粗略描述)
场景描述生成提示词
“根据给出的帧画面描述序列，将这些帧所属场景概括成连贯的段落。”
帧描述序列
场景描述聚合模型
冻结参数的大语言模型
"聚合帧描述序列信息为场景描述"
场景描述
场景1 ：厨师正在切桌子上的蔬菜。
场景2 ：厨师正在清洁打扫厨房。
帧级别
(详细描述)
帧描述生成器
视觉编码器
文本解码器
帧描述
帧描述生成器
文本解码器
视觉编码器
被冻结参数的大语言模型
无需任何额外参数和额外训练
场景1: "烹饪"
"根据帧视觉内容生成文本描述"
场景2: "清洁"